18.6

从观察中学习，决策树
使用决策树学习算法，从这些数据中得到决策树，

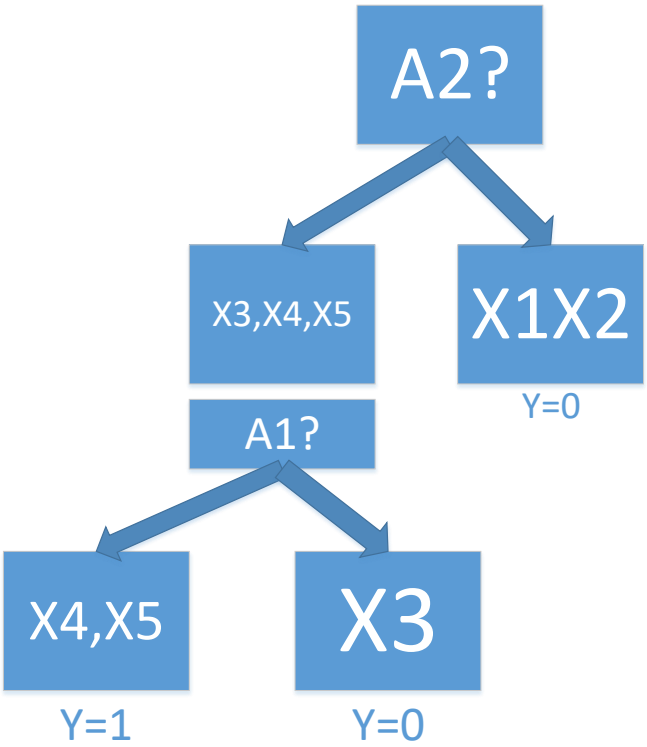

step 1:

$$Gain(A_2) = 1 - \left[\frac{2}{5} I(0,1) + \frac{3}{5} I\left(\frac{1}{3}, \frac{2}{3}\right)\right]$$

$$= 1 - \left[0 + \frac{3}{5} \times \left(-\frac{1}{3}\log_2\frac{1}{3} - \frac{2}{3}\log_2\frac{2}{3}\right)\right]$$

$$= 1 - \left[\frac{3}{5} \times -\frac{1}{5}\log_2\frac{1}{3} - \frac{2}{5}\log_2\frac{2}{3}\right]$$

$$= 0.449 \text{ bits}.$$

$$Gain(A_1) = 1 - \left[\frac{4}{5} I\left(\frac{1}{2}, \frac{1}{2}\right) + \frac{1}{5} I(0,1)\right]$$

$$= 1 - \left[\frac{4}{5} \times 1 + 0\right] = \frac{1}{5}$$

$$Gain(A_3) = 1 - \left[\frac{2}{5} I\left(\frac{1}{2}, \frac{1}{2}\right) + \frac{3}{5} I\left(\frac{1}{3}, \frac{2}{3}\right)\right]$$

$$= 1 - \left[\frac{2}{5} + \frac{3}{5}\left(\frac{1}{3}\log_2\frac{1}{3} + \frac{2}{3}\log_2\frac{2}{3}\right)\right]$$

$$= \frac{3}{5} - \left[+0.55\right]$$

$$= 0.049 \text{ bits}$$

$\therefore$ 选 A_2.

Step2

$$Gain(A_1) = 1 - \left[\frac{2}{3} I(0,1) + \frac{1}{3} I(1,0)\right] = 1 \text{ bits}.$$

$$Gain(A_3) = 1 - \left[\frac{2}{3} I\left(\frac{1}{2}, \frac{1}{2}\right) + \frac{1}{3} I(1,0)\right]$$

$$= 1 - \left[\frac{2}{3}\right] = \frac{1}{3} \text{ bits}$$

$\therefore$ 选 A_1.

Problem2　18.22

假设您有一个具有线性激活函数 activation 的神经网络。 也就是说，对于每个单位，输出是输入的加权总和的恒定 c 倍。

a。 假设网络具有一层隐藏层。 对于权重 w 的给定分配，写下输出层中单位值作为 w 和输入层 x 的函数的等式，而无需明确提及隐藏层的输出。证明有一个没有隐藏单元的网络可以计算相同的功能。

$$\mathrm{Y} = \mathrm{c}(\mathrm{w0} + \mathrm{X}^{\mathrm{T}}\ \mathrm{W}) + \mathrm{d}$$

Hidden $\mathrm{zi} = c\sum_{j=1}^{m} x_j w_{j,i}^{(1)} + d$

$$y_i = g(w_{0,i}^{(2)} + \sum_{j=1}^{d1} z_j w_{j,i}^{(2)}) = \ c(\sum_{j=1}^{d1} w_{j,i}^{(2)}(c\sum_{j=1}^{m} x_j w_{j,i}^{(1)} + d)) + d =$$

$$w = \sum_{j=1}^{m} w_{j,i}^{(2)} w_{j,i}^{(1)}$$

g(x) = $c^2 x + d(1 + c\sum_{j=1}^{m} w_{j,i}^{(1)})$

b。 重复（a）部分中的计算，但是这次是对具有任意数量的隐藏层的网络进行的。
就每层迭代既可.

C。 假设具有一个隐藏层和线性激活函数的网络具有 n 个输入和输出节点以及 h 个隐藏节点。 （a）部分向无隐藏层的网络的转换对权重总数有什么影响？ 特别讨论 h <<n 的情况

One layer: H*n input -> hidden, h*n hidden-> output, totally 2hn

No hidden layer: n^2

h<<n, so 2hn <<n^2 . The network with one hidden layer has fewer weights. So it has fewer mapping overhead. It could learn faster.